

HW1 - Deep learning -

سوال ۱۱ الف) در SVM، آنداده ای با هدف کم و آن داده support vector باشد، قاعده، قاعده در هر دو ندارد

ب) آنداده support vector باشد، قاعده ندارد است و سزا از داده هدف شده دوری شود چون ما خواسته $\|w\|$ را min کند. در رندسیون لا جیسیت هم داده ها قاعده ندارند و هدف یک داده مطلقاً تأثیر ندارد است.

ج) (i) طبقه بندی نادرست $\epsilon_i > 1$ طبقه بندی درست و سزا را در $\epsilon_i \leq 1$ و $0 \leq \epsilon_i$

نمادار طبقه بندی نادرست $\sum 1 > \sum \epsilon_i$
 طبقه بندی نادرست ϵ_i
 طبقه بندی نادرست ϵ_i

ii) آنداده مقدار کم باشد، ضریب های جیسیت اجازه عبور از margin را دارند.

$C \rightarrow \infty \rightarrow \text{Hard margin SVM} \rightarrow \text{narrow margin}$

$C \rightarrow 0 \rightarrow \text{large margin} \rightarrow \text{شرط سزا دامت در دریم طرفه می شود} \rightarrow \text{یک سزا در دو یقین می شود}$

iii)

SVM \leftarrow یک سزا ایجاد می کند و هدفش این است که Margin ماکزیمم باشد.

Logistic Regression \leftarrow با توجه به احتمال تعلق هر داده به کلاس سزا تعیین می شود با تابع sigmoid & softmax

آنداده یک داده بیست و محدود است باشد تأثیر آن بر SVM زیاد است اما بر LR ضعیف.

در SVM برای داده هایی که کاملاً قابل جداسازی باشند ضرب می کنند.

iv) Soft + SVM اجازه عبور برمی sample ها را می دهد اما هدف ماکزیمم کردن margin

است و می توان اجازه رد کردن Margin به C بستنی دارد. در صورتی که LR چون با احتمال

کلاس بندی را انجام می دهد می تواند بهتر عمل کند (در زمانی که جدا ساز خطی نباشند)

i)

$$\begin{aligned} \|\hat{m}_i - \hat{m}_j\| &= \|V_{1:k} z_i - V_{1:k} z_j\| = \underbrace{(V_{1:k} z_i - V_{1:k} z_j)^T}_{(z_i^T V_{1:k}^T - z_j^T V_{1:k}^T)} (V_{1:k} z_i - V_{1:k} z_j) \\ &= z_i^T \underbrace{V_{1:k}^T V_{1:k}}_I z_i - z_i^T V_{1:k}^T V_{1:k} z_j - z_j^T V_{1:k}^T V_{1:k} z_i + z_j^T V_{1:k}^T V_{1:k} z_j \\ &= z_i^T z_i + z_j^T z_j - z_i^T z_j - z_j^T z_i = (z_i - z_j)^T (z_i - z_j) = \|z_i - z_j\| \checkmark \end{aligned}$$

ii)

$$\begin{aligned} \sum_{i=1}^n \|\hat{m}_i - \hat{m}_i\|_2^2 &= (n-1) \sum_{j=k+1}^p \lambda_j \quad \hat{m}_i = V_{1:k} z_i = V_{1:k} V_{1:k}^T m_i \\ \Rightarrow \sum_{i=1}^n \|\hat{m}_i - \hat{m}_i\|_2^2 &= \sum_{i=1}^n \|m_i - V_{1:k} V_{1:k}^T m_i\|_2^2 = \sum_{i=1}^n \|(I - V_{1:k} V_{1:k}^T) m_i\|_2^2 \\ &= \sum_{i=1}^n \|V_{k+1:p} V_{k+1:p}^T m_i\|_2^2 = \sum_{i=1}^n m_i^T V_{k+1:p} V_{k+1:p}^T V_{k+1:p} V_{k+1:p}^T m_i \\ &= \sum_{i=1}^n m_i^T V_{k+1:p} V_{k+1:p}^T m_i = \sum_{i=1}^n (V_{k+1:p}^T m_i)^T (V_{k+1:p}^T m_i) \\ &= \sum_{i=1}^n \|V_{k+1:p}^T m_i\|^2 = \sum_{i=1}^n \sum_{j=k+1}^p (v_j^T m_i)^2 = \sum_{i=1}^n \sum_{j=k+1}^p v_j^T m_i m_i^T v_j \\ &= \sum_{j=k+1}^p \sum_{i=1}^n v_j^T m_i m_i^T v_j = \sum_{j=k+1}^p v_j^T \underbrace{\sum_{i=1}^n m_i m_i^T}_S v_j \\ &= (n-1) \sum_{j=k+1}^p \lambda_j v_j^T v_j = (n-1) \sum_{j=k+1}^p \lambda_j \checkmark \end{aligned}$$

$$Xw = y$$

$$X \sim \text{tall}$$

$$X \in \mathbb{R}^{m \times n}$$

$$m > n$$

سوال ۳: (الف)

جواب: ندارد

$$\min \|Xw - y\|^2$$

least square : و در فضای سون X سنی و قدر کمترین

حالت برای تصویر آن در فضای سون X به دست می آید

$$Xw = y$$

$$X \sim \text{تنگا سون} \Rightarrow X^T X \sim \text{invertable}$$

$$\Rightarrow X^T X w = X^T y \Rightarrow w = (X^T X)^{-1} X^T y$$

$$X = U \Sigma V^T \Rightarrow w = (V \Sigma^T U^T U \Sigma V^T)^{-1} V \Sigma^T U^T y$$

$$= (V \Sigma^T \Sigma V^T)^{-1} V \Sigma^T U^T y$$

$$= V \Sigma^+ \Sigma^T \underbrace{V^T V}_I \Sigma^T U^T y$$

$$\Rightarrow w = V \Sigma^+ U^T y = V \begin{bmatrix} \frac{1}{\sigma_1} & 0 & \dots & 0 \\ 0 & \dots & \frac{1}{\sigma_n} & 0 \end{bmatrix} V^T y$$

$$A \backslash b = (X^T X)^{-1} X^T b \sim \text{معکوس}$$

$$Xw = y$$

$$\min w^T w$$

$$Xw = y$$

$$\mathcal{L}(w, \lambda) = w^T w + \lambda^T (Xw - y)$$

$$\nabla_w \mathcal{L} = 2w + X^T \lambda = 0$$

$$\nabla_\lambda \mathcal{L} = Xw - y = 0$$

$$\Rightarrow w = -\frac{1}{2} X^T \lambda$$

$$\Rightarrow -\frac{1}{2} X X^T \lambda = y \Rightarrow \lambda = -2 (X X^T)^{-1} y$$

$$\Rightarrow w = X^T (X X^T)^{-1} y$$

$$X = U \Sigma V^T$$

$$w = V \Sigma^T U^T (U \Sigma \underbrace{V^T V^T}_{1} \Sigma^T U^T)^{-1} y$$

(8)

$$= V \Sigma^T U^T U \Sigma^+ \Sigma^+ U^T y$$

$$= V \Sigma^+ U^T y = V \begin{bmatrix} \frac{1}{\sigma_1} & & & \\ & \ddots & & \\ & & \frac{1}{\sigma_m} & \\ 0 & \dots & 0 & \end{bmatrix} U^T y$$

$$X^+ = X X^T (X X^T)^{-1} = I \leadsto \text{معموسه، اسه}$$

(9)

$$l(w) = \frac{1}{2} \|y - Fw\|_2^2 \quad \nabla_w l(w) = \frac{\partial}{\partial w} \left(\frac{1}{2} (Fw - y)^T (Fw - y) \right) = F^T (Fw - y)$$

$$H = \frac{\partial}{\partial w} (F^T (Fw - y)) = F^T F$$

تقریب مسد متیلور $\leadsto \hat{l}(w) = l(w^*) + \underbrace{(w - w^*)^T \nabla_w l(w^*)}_{\text{میلور}} + \frac{1}{2} (w - w^*)^T H (w - w^*)$

$$\Rightarrow \hat{l}(w) = l(w^*) + \frac{1}{2} (w - w^*)^T H (w - w^*) \Rightarrow \nabla_w \hat{l}(w) = H(w - w^*) = F^T F (w - w^*)$$

$$\nabla_w l(w^*) = 0 \Rightarrow F^T (Fw^* - y) = 0 \Rightarrow F^T F w^* = F^T y$$

$$\Rightarrow \nabla_w \hat{l}(w) = F^T F w - F^T y \leadsto \text{gradient descent: } w_t = w_{t-1} - \eta (F^T (Fw_{t-1} - y))$$

$$w_t = w_{t-1} - \eta F^T F w_{t-1} + \eta F^T y$$

$$\Rightarrow w_t = (I - \eta F^T F) w_{t-1} + \eta F^T y$$

مسیر $\Rightarrow \|w_t\| \leq \|(I - \eta F^T F) w_{t-1}\| + \eta \|F^T y\|$

کوینس شارتر $\|F^T y\| \leq \|F^T\| \|y\| = \alpha \|y\|$

$$\|(I - \eta F^T F) w_{t-1}\|_2 \leq \|I - \eta F^T F\| \|w_{t-1}\|$$

$$F^T F = Q \Lambda Q^T \leadsto I - \eta F^T F = I - \eta Q \Lambda Q^T = Q (I - \eta \Lambda) Q^T$$

$$\|I - \eta F^T F\| = \|Q(I - \eta L)Q^T\| \leq \underbrace{\|Q\|}_1 \|I - \eta L\| \underbrace{\|Q^T\|}_1 = \|I - \eta L\|_2$$

$$\leq \sqrt{\lambda_{\max}((I - \eta L)^T(I - \eta L))} \rightarrow \max_{\lambda} (1 - \eta \sigma_{\min}^2)^2 \rightarrow \lambda_{\max} < 1$$

$0 \leq \sigma_{\min}^2 \leq 1$

$$\Rightarrow \|I - \eta L\|_2 < 1 \Rightarrow \|I - \eta F^T F\| < 1 \Rightarrow \|I - \eta F^T F\|_2 \|w_{t+1}\| \leq \|w_{t+1}\|_2$$

$$\Rightarrow \|(I - \eta F^T F) w_{t+1}\| \leq \|w_{t+1}\|_2$$

قضیہ داسم $\|F^T y\| \leq \alpha \|y\|$ ، $\|w_t\| \leq \|(I - \eta F^T F) w_{t+1}\| + \eta \|F^T y\|$

$$\Rightarrow \|w_t\|_2 \leq \|w_{t+1}\|_2 + \eta \alpha \|y\|_2 \quad \checkmark$$

$$1 < \|I - \eta F^T F\| = \|I - \eta L\|_2 = |1 - \eta \sigma_{\min}^2|$$

آپ ڈائریکٹوریٹ سے $|1 - \eta \sigma_{\min}^2| > 1$

سوال ٥ : (١٢)

$$E_{Y \sim P(Y|m), D} [(Y - \hat{f}_{\theta(D)}^{(m)})^2] = E_{Y \sim P(Y|m), D} [\hat{f}_{\theta(D)}^{(m)} - Y]^2 + E_D [(\hat{f}_{\theta(D)}^{(m)} - E_D[\hat{f}_{\theta(D)}^{(m)}])^2] + \sigma^2$$

$$E_{Y \sim P(Y|m), D} [(Y - h(m) + h(m) - \hat{f}_{\theta(D)}^{(m)})^2] \\ = E_{Y \sim P(Y|m), D} [(Y - h(m))^2 + (h(m) - \hat{f}_{\theta(D)}^{(m)})^2 + 2(Y - h(m))(h(m) - \hat{f}_{\theta(D)}^{(m)})] \\ = E[(Y - h(m))^2] + E[(h(m) - \hat{f}_{\theta(D)}^{(m)})^2] + 2E[(Y - h(m))(h(m) - \hat{f}_{\theta(D)}^{(m)})]$$

$E[(h(m) - \hat{f}_{\theta(D)}^{(m)}) E(\underbrace{Y - h(m)}_{\epsilon \sim N(0, \sigma^2)})] = 0$

$$= \underbrace{E[(Y - h(m))^2]}_{\text{noise}} + E[(h(m) - \hat{f}_{\theta(D)}^{(m)})^2] \quad \bar{f} = E_D[\hat{f}_{\theta(D)}^{(m)}]$$

$$E[(h(m) - \bar{f} + \bar{f} - \hat{f}_{\theta(D)}^{(m)})^2] = E[(\bar{f} - \hat{f}_{\theta(D)}^{(m)})^2 + (h(m) - \bar{f})^2 + 2(h(m) - \bar{f})(\bar{f} - \hat{f}_{\theta(D)}^{(m)})] \\ = E \left[\underbrace{E_D((\bar{f} - \hat{f}_{\theta(D)}^{(m)})^2)}_{\text{var}(m)} + \underbrace{E_D((h(m) - \bar{f})^2)}_{\text{bias}(m)} \right]$$

= Var + bias

$$\Rightarrow E[(Y - \hat{f}_{\theta(D)}^{(m)})^2] = E[(Y - h(m))^2] + E[(\bar{f} - \hat{f}_{\theta(D)}^{(m)})^2] + E[(\bar{f}(m) - h(m))^2]$$

= noise + var + bias

$$y = X\theta^* + \varepsilon$$

$$\hat{\theta} = (X^T X)^{-1} X^T y$$

(4)

$$\text{bias} = n^T \theta^* - E_D [n^T \hat{\theta}] = n^T \theta^* - E_D [X^T (X^T X)^{-1} X^T y]$$

$$= n^T \theta^* - E_D [X^T (X^T X)^{-1} X^T (X\theta^* + \varepsilon)]$$

$$= n^T \theta^* - E_D [X^T \theta^*] - E_D [X (X^T X)^{-1} X^T \varepsilon]$$

$$= n^T \theta^* - \underbrace{E_D [X^T \theta^*]}_{n^T \theta^*} - \underbrace{X (X^T X)^{-1} X^T E[\varepsilon]}_0 = 0$$

$$\text{var} = E[(\varphi_D(m) - \bar{\varphi}_D(m))^2] = E[(n^T \hat{\theta} - \underbrace{E_D[\varphi_D(m)]}_{n^T \theta^*})^2]$$

مقدار $\leftarrow X^T \theta^*$

$$= E[(X^T (X^T X)^{-1} X^T \overset{X\theta^* + \varepsilon}{y} - X^T \theta^*)^2] = E[(X^T \theta^* + X^T (X^T X)^{-1} X^T \varepsilon - X^T \theta^*)^2]$$

$$= E[X^T (X^T X)^{-1} X^T \varepsilon \varepsilon^T X (X^T X)^{-1} X] = X^T (X^T X)^{-1} X^T \underbrace{E[\varepsilon \varepsilon^T]}_1 X (X^T X)^{-1} X$$

var(ε_i) = 1
مقدار \leftarrow

$$= X^T (X^T X)^{-1} X^T X (X^T X)^{-1} X = X^T (X^T X)^{-1} X$$